

Runtime Stop MVP

CIP/PAL 本体／高リスク実行 Safety Profile 統合 Proposal（CHG-027～032 反映版）

STATUS Proposal v0.5 Producer Approved • CHG-027～032 反映済み • Producer 承認済み。監査承認および最終 ADOPT は後日判断する。本版は 2026 年 8 月 19 日付 Proposal v0.4 Fixed を上書きせず、承認された Material 変更を新 version へ反映したものである。Producer 承認は本文内容の承認に限定され、v0.5 の最終 ADOPT、Safety Profile Activation、Approved P_A の発効または B'採否を意味しない。

項目	内容
文書版	Proposal v0.5 Producer Approved（CHG-027～032 Incorporated／Audit Approval and Final ADOPT Pending）
基準日	2026 年 9 月 19 日
作成入力	2026 年 8 月 19 日付 Proposal v0.4 Fixed、Anthropic Life Sciences Verification Program および 2026 年 9 月 Threat Intelligence Report から得た運用上の知見、ならびに人間が承認した CHG-027～032 と構造化 diff
基本系列	$A \rightarrow (A + C) \rightarrow A' \rightarrow B' \neq B$
構成	Part I：CIP/PAL Core／Part II：High-Risk Execution Safety Profile／Part III：Governance & Transition
最終権限	Canonical A の確定、Safety Profile の適用、停止解除、B'採用はいずれも人間が決定

エグゼクティブサマリー

本 v0.5 Producer Approved 版は、CIP/PAL を AI 媒介の認識・適合評価の本体と、高リスクな外部実行を制御する Safety Profile に分離する。CIP/PAL Core は、AI が A をそのまま通過させず、C を介して A' を形成し、実出力 B' が意図された B と自動的に同一ではないことを扱う。Runtime Gate、watchdog、Capability Token、累積予算、停止線形化時点 T_k などは Core の必須要素ではなく、高リスク実行時に限って適用する追加 Profile とする。

PAL の PASS/FAIL/INSUFFICIENT EVIDENCE は、一つの assessment_id に対する終端判定とする。FAIL または INSUFFICIENT EVIDENCE だけを理由として Human Checkpoint を反復生成せず、自動再評価もしない。追加証拠を取得する場合は有限の取得予算を設定し、別 assessment_id として一度だけ再評価する。解消しない場合は CLOSED—UNRESOLVED として終了する。

Human Checkpoint は、不確実性一般の受け皿ではなく、人間に留保された決定権を行使する場面だけに限定する。これにより、判断責任を人間へ返し続ける循環を防ぎつつ、Canonical A、例外、高リスク実行、停止解除、B' 採用に関する人間の最終権限を保持する。

v0.5 の要点 CIP/PAL Core は軽量な規範・評価層とし、強制装置を内包しない。Safety Profile は条件付きで有効化され、管理境界内の副作用経路だけを拘束する。

0. 文書の位置づけと承認境界

本書は、2026 年 8 月 19 日付 Proposal v0.4 Fixed を authoritative baseline として保持し、人間が採用を承認した CHG-027～032 を Material 変更として反映した v0.5 Producer Approved 版である。v0.4 Fixed を差し替えず、Producer による本文内容の承認を 2026 年 9 月 19 日付で記録する。監査承認および v0.5 の最終 ADOPT は別途記録する。本版の Producer 承認は Safety Profile Activation、Approved P_A の発効または B'採否へ自動的に拡張しない。人間が選択・整理・承認した Context だけを Canonical A として扱い、C、A'、B'、P_A candidate、Approved P_A、実行状態および監査証拠と混同しない。

区分	本書での扱い	承認
CIP/PAL Core	一般利用に適用する規範・評価モデルの提案	CHG-027～032 反映済み・Producer 承認済み。監査承認および最終 ADOPT は別途判断
Safety Profile	高リスク実行へ条件付き適用する追加統制案	Producer 承認済み。監査承認および最終 ADOPT と分離し、適用環境ごとに Activation を人間が判断
実装パラメータ	ツール、予算、timeout、鍵、保持期間など	Profile Activation Package で確定
試験結果・ログ	採否判断の証拠。規範そのものではない	内容を『承認』せず、証拠として受理／棄却
参考説明・技術例	Informative。別方式を許容	個別承認不要

Part I — CIP/PAL Core

1. 目的と適用範囲

CIP/PAL Core の目的は、AI または実行構造による媒介を不可視化せず、人間が確定した Canonical A と、そこから派生した A' および B' を区別し、B' の採否を A への適合性と証拠に基づいて判断可能にすることである。

Core は、文章生成、分析、設計、画像生成、コード生成、計画、評価など、外部副作用を伴わない利用にも適用できる。Core 自体は Runtime Gate、ネットワーク遮断、watchdog、資格情報分離その他の実行強制装置を要求しない。

2. 基本系列と定義

固定系列 $A \rightarrow (A + C) \rightarrow A' \rightarrow B' \neq B$

記号	定義
A	人間が選択・整理・承認した Canonical Context。目的、制約、判断基準、参照情報等の正本。
C	モデル側または実行構造側の媒介。解釈、変換、補完、圧縮、計画、ツール応答、環境状態等を含む。
A'	C を経て再構成された、モデル側または実行側の作業表現・解釈・計画・状態。
B	媒介がなかったと仮定した理想的・意図的結果の参照概念。直接観測できるとは限らない。
B'	実際に生成、提示または実行された結果。
B' ≠ B	失敗の断定ではない。B' を B と自動同一視できず、採否に評価が必要であることを示す。

3. Core の不変条件

- Canonical A は人間が確定する。モデルの要約、推定、再構成または補完は A ではない。
- C は A に付加されて A' を形成する媒介であり、C だけを独立した目的・正本として扱わない。
- A' または B' を、明示的な人間判断なしに Canonical A へ逆流させない。

- Cを完全に観測・除去・支配できるとは主張しない。観測可能な証拠だけを評価する。
- PAL は必要に応じ、単一 Action だけでなく、同一 run_id に属する観測可能な活動系列を評価できる。監視による異常候補の検出と Runtime Gate による実行遮断は別の機能であり、Canonical A の変更および B'の採否に関する最終判断は人間に属する。
- PAL は Conformance Assessment Layer であり、強制装置でも、真理判定器でも、承認主体でもない。
- B'の採用、拒否または改訂要求は人間の判断として記録する。

4. CIP/PAL の有限ライフサイクル

1. 人間が Canonical A の版、範囲、判断基準を確定する。
2. Producer が A を直接参照して生成・処理を開始し、観測可能な C を記録する。
3. モデルまたは実行構造が A'を形成し、B'候補を生成する。
4. PAL が A、A'、B'および証拠を照合し、一つの assessment_id へ一つの終端判定を記録する。
5. 人間が必要な場合に限り B'を ADOPT、REJECT または REQUEST REVISION と判断する。
6. 改訂する場合は、新しい入力・版・assessment_id で開始し、旧判定を再帰的に開き直さない。

5. PAL 判定と循環排除

PAL 判定	意味	終端処理
PASS	定義済み基準と必要証拠を満たす。	当該 assessment を COMPLETED—PASS として閉じる。採用または実行を自動許可しない。
FAIL	少なくとも一つの基準に不適合。	当該 assessment を COMPLETED—FAIL として閉じ、対象候補を棄却または隔離する。自動再試行しない。
INSUFFICIENT EVIDENCE	判定に必要な証拠が欠ける、または評価間不一致が解消できない。	当該 assessment を COMPLETED—INSUFFICIENT として閉じる。Human Checkpoint を自動生成しない。

5.1 追加証拠の取得

追加証拠を取得できる場合は、当初の Canonical A または人間が別途定めた有限予算の範囲で、一回の Evidence Acquisition を許可できる。取得後は新しい assessment_id を作成し、旧判定は変更しない。証拠が得られない、期限を超える、または新 assessment でも INSUFFICIENT EVIDENCE となった場合は CLOSED—UNRESOLVED として終了する。

禁止 INSUFFICIENT EVIDENCE → Human Checkpoint → 再評価 → INSUFFICIENT EVIDENCE という自動循環を構成しない。人間が何もしないことも正当な終端である。

5.2 Human Checkpoint の限定トリガー

Human Checkpoint は、不確実性の存在だけでは起動しない。次のように人間へ留保された決定権を行使するときだけ起動する。

- Canonical A の新規確定、変更、失効または例外設定
- B' の正式採用、拒否または改訂要求（運用上、明示的採否が必要な場合）
- Safety Profile の Activation、Approved P_A、限定 Go または適用範囲の変更
- Safety Profile 下の L2 操作、例外的リスク受容、停止解除または新 run への再開
- 法令、契約または組織規則によって人間判断が要求される事項

FAIL、INSUFFICIENT EVIDENCE、安全な拒否、隔離、停止、証拠保存は、それ自体では Human Checkpoint を必要としない。安全側の終了を承認待ちにしてはならない。

6. Validation から Adoption まで

機能	Core での意味
validation	A への適合性と証拠充足性を評価する。
rejection	不適合候補を採用・実行経路から除外する。ここでの rejection は処理上の除外・隔離であり、人間による B' の正式な REJECT とは別イベントである。

機能	Core での意味
purge	汚染または不適合が疑われる管理下の派生状態を再利用不能にする。 Safety Profile 下では、purge は一括削除ではなく、実行能力の失効、汚染状態の隔離および再利用防止を意味する。Canonical A および必要な監査証拠は purge の削除対象としない。
re-binding	新しい処理を、明示された Canonical A の版および人間が承認した scope へ再拘束する。Safety Profile 下の re-binding は、旧 run、旧 Token、旧承認または汚染状態の再開を意味しない。
re-convergence	新しい入力と assessment_id で再生成・再評価する。Safety Profile 下では新しい run_id を使用し、自動的な旧 run 再開ではない。
adoption	人間が B' を成果物として採用する。実行許可や PAL PASS とは別イベント。

7. Core が主張すること／しないこと

主張する	主張しない
A、C、A'、B' の役割を分離し、出力を A と自動同一視しない。	C の完全観測、完全除去または直接制御。
PAL 判定を有限の assessment へ閉じ、再帰的な承認要求を防ぐ。	$B' \neq B$ が常に失敗または危険を意味すること。
人間の採否権限とモデル由来状態を分離する。	PAL PASS だけで品質、安全、真実性または実行許可が確定すること。

Part II — High-Risk Execution Safety Profile

8. Profile の位置づけと Activation

Safety Profile は CIP/PAL Core の一部ではなく、外部副作用を伴う高リスク実行へ追加する条件付き Profile である。Profile を適用しない CIP/PAL 利用が存在してよい。Activation はモデルではなく人間が決定し、対象環境、ツール、資格情報、通信先、データ、操作、期間および責任者を境界台帳へ固定する。

Activation 候補	例
外部書込み・送信	メール送信、公開、外部 DB 更新、第三者 API への変更要求
機密・個人・認証情報	資格情報の使用、機密データ処理、権限付きアクセス
不可逆性または広範囲影響	削除、権限変更、大量操作、金銭・契約・安全に関わる処理
自律的反復	長時間 run、サブエージェント、連続 dispatch、累積的な範囲拡張

Activation 原則 該当する可能性だけで自動 Activation しない。人間が高リスク実行として指定した境界にのみ Profile を適用する。

9. 役割と権限分離

構成要素	役割	禁止事項
人間／Producer	Canonical A、Profile Activation、Approved P_A、例外、停止解除、B'採用	判断権限のモデル委譲
Canonical A Registry	署名済み A、版、条項 ID、失効状態を保持	モデル出力による直接更新
Chat 1	Prompt 候補、条項対応、未解決事項を生成	ツール実行、A の変更
Monitor	観測可能な実行軌跡を収集し、異常候補と critical flag を生成	ツール実行、Gate 状態変更、自己判断による再開
Chat 2／PAL Investigator	Preflight PAL として単一 Action または同一 run_id の活動系列を評価し、PASS／FAIL／INSUFFICIENT EVIDENCE を提示	Prompt 修正、通常ツール実行、Gate 状態変更、自己判断による再開、反復 Checkpoint 生成

構成要素	役割	禁止事項
Chat 3	Action Proposer として Action Envelope 候補を提出	資格情報保持、直接実行
Runtime Gate	Approved P_A だけを参照し、管理境界内の唯一の許可副作用経路として dispatch を決定	自然言語根拠、candidate、失効 policy による許可
外部 watchdog	Gate、Token、egress、ログを監視し、事前承認済み条件に基づき凍結、安全停止または隔離	障害後の LLM による即興分類
監査領域	改変耐性・改変検知性・順序検証性のある証拠保存	実行系からの削除・上書き

10. Canonical A、P_A candidate、Approved P_A

artifact	状態と使用条件
Canonical A	人間が承認した規範的要求。直接の機械的実行許可として解釈しない。
P_A candidate	A から C を介して生成された機械強制ポリシー候補。Canonical A ではなく、Gate は使用禁止。
Approved P_A	対応表、差分、未実装要求、例外を人間が確認し、特定の A version/hash、環境、run へ拘束した実行ポリシー。

A から P_A candidate への変換は C として、入力 A version/hash、変換主体、手順またはモデル識別情報、生成時刻、候補 hash、未解決事項を記録する。Canonical A 更新時は、旧 A に拘束された Approved P_A および未消費 Token を失効し、対象 run を SUSPENDED とする。

11. リスク区分と Human Checkpoint

区分	対象	処理
L0	非機密・許可範囲内の読み取り	Gate が自動許可可能
L1	可逆的で限定的な管理下変更	Gate 検査・ログ。事前承認済み範囲なら個別 Checkpoint 不要
L2	外部通信・書込み、資格情報、機密情報、重要な対外効果	正規化済み Action ごとの Human Checkpoint

区分	対象	処理
L3	削除、権限変更、不可逆操作、未承認範囲拡張	MVP では Capability を実装せず、権限上不可能

12. Runtime 実行フロー

1. 人間が Canonical A と Safety Profile Activation Package を確定する。
2. P_A candidate を生成し、変換 C、対応表、差分、未実装要求、例外を提示する。
3. 人間が Approved P_A を A version/hash、環境 fingerprint、run 範囲へ拘束する。
4. Chat 1 が候補を生成し、Chat 2 が一つの assessment_id へ PASS／FAIL／INSUFFICIENT EVIDENCE を返して閉じる。
5. PASS の場合だけ Chat 3 が Action Envelope 候補を提出する。Chat 3 は実行しない。

実行中、Monitor は同一 run_id について、Action proposal、tool、target、normalized_args、Gate 判定履歴、外部状態 version／ETag、成功・失敗・再試行、対象・宛先・権限 scope の変化、累積操作数・送信量・費用・並列数、停止または拒否後の再 dispatch 試行、ならびに Canonical A および Approved P_A との累積差分を正規化済み活動系列として記録する。planning summary その他モデルが明示的に出力した推論情報は、不完全で信頼済みではない補助証拠としてのみ扱い、非公開または完全な chain-of-thought の取得や、内部推論と実動作意図の一致を安全保証の前提としない。

監視段階は、リスク区分 L0～L3 と区別して M1／M2 と呼ぶ。M1 は低遅延の決定論的検査および軽量検出、M2 は懸念発生時の精密 PAL 評価とする。M1 で異常を検出しなくても、Runtime Gate の allowlist、引数 schema、対象、宛先、操作種別、権限 scope および累積予算の独立した決定論的検査を省略しない。Monitor または PAL の PASS は Gate の PERMITTED と同一ではない。必要な監視証拠を取得できない高リスク処理は INSUFFICIENT EVIDENCE として閉じ、新規 dispatch を拒否または凍結し、Human Checkpoint を自動生成しない。

6. Gate が Action を独立に正規化し、Approved P_A、schema、予算、環境、状態を決定論的に検査する。

7. L2 の場合だけ、Gate が生成した実操作を Human Checkpoint へ一度提示する。REJECT または期限切れは終了し、再提示を自動反復しない。

Human Checkpoint は、同一の run_id、action_hash、Canonical A hash、Approved P_A hash、外部状態 version および証拠集合について重複提示しない。新しい証拠、Action 差分、外部状態変更または期限切れがない限り再審査を発生させない。REQUEST REVISION 後は新しい action_hash を持つ候補として扱い、人間が REJECT した Action を言い換えまたは分割して再提示しない。INSUFFICIENT EVIDENCE の理由と解消に必要な証拠は一度だけ具体化し、自動解消できなければ SUSPENDED で固定する。Checkpoint 通過は B' の自動採用を意味しない。

8. Gate が single-use Token、action_hash、状態 precondition を再検証し、完全一致する操作を一度だけ dispatch する。
9. 実副作用と状態差分を記録し、B' 採用は実行許可と別の人間判断として扱う。

12.1 Canonical A Transmission Preflight

High-risk 実行について、Chat 3 が Action Envelope 候補を提出する前に、Chat 2/PAL Investigator は、実行系へ伝達された入力を Canonical A Registry の署名済み版、A version/hash、Approved P_A および失効状態と独立に照合しなければならない。

Preflight は、少なくとも次の状態を検査する。

- Canonical A の条項、制約、禁止事項または判断基準の欠落
- 要約、圧縮または言い換えによる意味変更
- 別 task の指示または未承認 Context の混入
- モデルが生成した推定、補完、計画、A'、B' または実行状態の Canonical A への混入
- Canonical A、Approved P_A、環境または実行 scope の版不一致
- 失効した Canonical A または Approved P_A の使用

Preflight は PASS、FAIL または INSUFFICIENT EVIDENCE を一つの assessment_id に対する終端判定として記録する。PASS 以外の場合、Chat 3 は Action Envelope 候補を Runtime Gate へ提出してはならず、新規 dispatch を発生させてはならない。

モデルは、不整合を解消するために Canonical A を要約、補完、再構成または自己修正してはならない。修正が必要な場合は、署名済み正本を再提示するか、人間が新しい Canonical A を明示的に確定する。

Preflight PASS は、PAL による Action 評価、Human Checkpoint、Runtime Gate の決定論的検査、action_hash による承認または B' adoption を代替しない。

12.2 Execution Continuity Invariant

管理境界内で、同一の承認済み実行系列に属することが明示的に確認された session、chat、credential、model、agent、tool、route または管理下 account の変更は、次の状態を自動的に初期化、解除または消去してはならない。

- 累積予算および既消費量
- Canonical A および Approved P_A との binding
- authorization scope
- rejection state および suspension state
- purge state および残存状態
- 未完了の conformance assessment
- 保留中、取消済みまたは拒否済みの Action
- 停止イベント、 T_k および停止後禁止

Runtime Gate は、同一実行系列に属すると決定論的に確認された遷移について、これらの状態を権威ある状態ストアから継承しなければならない。session、credential、model、route その他の識別子を変更したことだけを理由に、新しい安全状態から開始してはならない。

状態を解除または変更して実行を再開する場合、人間による明示的な再承認、Canonical A および scope への re-binding、新しい run_id、必要な新しい action_hash、nonce および外部状態 version の確認を必要とする。旧 run は再開しない。

新しい Canonical A を作成したことだけでは、既存の rejection、suspension、purge、予算消費または残余リスクを洗浄しない。人間が目的、scope、主体および残存状態を確認し、従前の実行系列との関係を明示的に判断しなければならない。

execution lineage は、複数の管理対象実行を Canonical A の版、承認履歴、累積予算および停止状態へ結び付ける運用上の相関単位であり、基本系列 $A \rightarrow (A + C) \rightarrow A' \rightarrow B' \neq B$ の新しい要素ではない。execution lineage は action_hash による個別承認を代替しない。

12.3 Post-execution PAL and Sequence Review

Safety Profile が有効な実行系列について、独立した post-execution PAL を実施しなければならない。評価は、提案または承認された Action だけではなく、実際の dispatch、実副作用、外部状態差分、失敗、再試行、予算消費および観測可能な累積結果を対象とする。

post-execution PAL は Preflight と異なる assessment_id を使用し、Canonical A、Approved P_A、Action Envelope、Gate 判断および実行証拠を照合する。必要な場合、単一 Action だけでなく、同一 execution lineage に属する観測可能な活動系列を評価する。

対象 run は、必要な post-execution assessment が終端する前に COMPLETED としてはならない。FAIL または INSUFFICIENT EVIDENCE の場合、未実行の新規 dispatch を拒否または凍結し、run を SUSPENDED または TERMINATED として処理し、必要に応じて purge、インシデント調査または人間による残余リスク評価へ接続する。

post-execution PAL は、Preflight PAL、Human Checkpoint、Runtime Gate または action_hash による事前承認を代替しない。事後評価によって、過去の未承認実行を遡及的に許可してはならない。

post-execution PASS は、B' の ADOPT、品質、安全性または目的達成を自動的に確定しない。B' adoption は引き続き独立した人間判断とする。

offline PAL は post-execution 評価または追加調査に使用できるが、Runtime Gate を経由する実時間の許可・拒否を置換してはならない。

12.4 High-risk Circumvention Correlation

Safety Profile Activation Package で指定された高リスク境界について、Monitor または PAL は、rejection または suspension された同一または実質的に同一の実行目的が、別の session、credential、model、account、route または中継 service を用いて再開された可能性を circumvention candidate として評価できる。

管理下の識別子、承認記録または明示的な execution lineage の関係が一致する場合、既存の rejection、suspension、purge、予算および未解決 assessment の状態を決定論的に継承する。

未知の identity、管理外経路または実質的同一性の評価は確率的判断であり、circumvention candidate の検出だけで違反、悪意または同一主体を確定してはならない。候補は、証拠、確度、反証可能性および対象範囲を記録して人間の評価へ送る。

model、account、credential または route の変更だけを circumvention とみなしてはならない。目的、対象、操作系列、時間的關係、承認履歴、rejection／suspension 状態その他の観測可能な証拠を組み合わせる。

Activation Package で事前承認されたリスク閾値に達した場合、違反確定とは分離した安全措置として、新規高リスク dispatch を一時的に SUSPENDED とすることができる。停止解除には人間の明示的判断を必要とし、候補検出だけを理由に管理外 account または外部 service へ処置を行ってはならない。

CIP/PAL は、他社 account の停止、他社 traffic の直接監視または管理外経路の完全な検出を保証しない。観測できない外部経路は残余リスクとして記録する。

13. Action Envelope と原子的承認

区分	拘束項目
実行識別	run_id、assessment_id、A_hash、Approved P_A hash、prompt_hash、action_hash
実体	tool、target、normalized_arguments、environment identifier
状態	state precondition、version／ETag、残り予算、configuration fingerprint
承認	approver、decision、nonce、expires_at、single_use
影響	expected side effect、rollback／compensation、risk level、budget consumption

承認対象と実行対象は、版管理された canonical serialization から算出した action_hash へ拘束する。tool、target、arguments、budget、A version/hash または security-relevant configuration fingerprint が変化した場合、旧承認と Token を失効する。更新 Action は新しい提案として提示するが、自動承認要求を反復しない。

14. 状態機械と終端性

状態機械	状態	終端・分離原則
PAL assessment	OPEN / COMPLETED—PASS / COMPLETED—FAIL / COMPLETED—INSUFFICIENT / CLOSED—UNRESOLVED	— assessment_id につき一終端判定。再評価は新 ID。
Gate 判断	PENDING / PERMITTED / DENIED	DENIED は run 終了や B'拒否と同義ではない。
run	ACTIVE / SUSPENDED / TERMINATED / COMPLETED	停止時はまず SUSPENDED。旧 run を再利用しない。
Token	ISSUED / CONSUMED / EXPIRED / REVOKED	— Action • single-use。
B' adoption	PENDING / ADOPTED / REJECTED / REVISION REQUIRED	Gate 許可および PAL 判定と別イベント。
監視状態	NORMAL / DEGRADED / UNAVAILABLE	必要な監視が成立しない高リスク処理は fail-closed。黙って省略せず、自動 Checkpoint も生成しない。

execution lineage は run の上位に置かれる理論状態ではなく、複数の管理対象 run に共通する承認、予算、停止および purge 状態を相関する運用単位である。新しい run_id の発行は、関連する execution lineage の状態を自動的に ACTIVE へ戻さない。

post-execution assessment が必要な run は、その assessment が終端するまで COMPLETED へ遷移してはならない。必要な実行証拠を取得できない場合、COMPLETED とせず、リスクに応じて SUSPENDED または TERMINATED とする。

15. T_k 、Kill Switch、限定停止保証

T_k 認証・完全性検証に成功した権威ある停止イベントについて、Runtime Gate の権威ある状態ストアで、Gate 判断 DENIED と対象 run の停止バリアが原子的に確定した時点。可能な場合は run 状態 SUSPENDED も同一原子操作で確定する。個別 Action に対する通常の Gate 判断 DENIED は action denial であり、それだけでは T_k を成立させない。 T_k を成立させる停止イベン

トは、事前定義された停止条件、認証済み Kill Switch 要求、または watchdog による権威ある停止判定に限る。

Critical flag は Monitor が生成する凍結要求であり、それ自体は Gate 状態を変更せず T_k も成立させない。Runtime Gate または外部 watchdog が事前承認済み trigger、署名および対象 run を検証し、Gate 判断 DENIED、停止バリアおよび run 状態 SUSPENDED を権威ある状態ストアへ原子的に確定する。この commit を T_k とし、M2 または人間による調査完了を待たず、以後の対象となる新規高リスク dispatch を拒否する。期限までに PASS を立証できない場合は SUSPENDED を維持する。継続には、人間の明示的承認、新しい run_id、action_hash、nonce および外部状態 version の再確認を必要とし、旧 run は再開しない。

検出保証は、観測可能な異常候補を flag として提示できる範囲である。遮断保証は、 T_k 以降、Runtime Gate 経路の対象となる新規 dispatch を拒否できる範囲である。 T_k 以前に commit 済みの作用、管理境界外のコピーおよび未知の副作用経路は停止保証の対象外とし、purge は PURGE VERIFIED / PURGE PARTIAL / PURGE UNVERIFIABLE で別途評価する。警告、通知または停止期待を、技術的な実行遮断と同一視しない。

T_k 以降、対象 run に関する新規 Token 発行、新規 PERMITTED 判断、新規副作用操作の許可、新規 dispatch および新規開始を禁止する。保証対象は、承認済み MVP 管理境界内の定義済み副作用経路における未承認の新規操作に限定する。

- 新規承認と Token 発行を停止する。
- 新規 dispatch と新規 egress を遮断する。
- 発行済み Token を失効する。
- 管理下のキュー、ジョブ、ソケット、サブエージェントを取消または隔離する。
- テレメトリと状態証拠を監査領域へ封印する。

T_k 前に dispatch 済みまたは外部 commit 済みの処理、管理外コピー、未知の経路は保証対象外とする。操作登録時に cancel、rollback、compensating action、受信側状態確認を定義し、備えられない不可逆操作は L3 として MVP から除外する。

16. 安全操作、watchdog、purge

REJECT、SUSPEND、SHUT DOWN、資格情報失効、および事前登録済みのインシデント申告は、通常承認予算と冷却期間の対象外とする。ただし、認証、権限確認、署名検証、監査、idempotency は必須とし、重複要求を同一停止効果へ収束させる。インシデント申告は、Profile Activation Package で人間が承認した宛先、固定 schema、データ最小化、添付禁止および資格情報除外の範囲に限る。未登録宛先、自由記述の外部送信または追加データの添付は安全操作に含めず、L2 として扱う。安全な拒否・停止・隔離は Human Checkpoint を待たずに実行できる。

16.1 watchdog と purge

watchdog は Gate と異なる管理プレーンに置く。障害後に LLM が操作分類を生成せず、ツール登録時に人間が承認した「安全停止可能／状態不明／強制終了可能」の分類を使用する。未分類、期限切れ、版不一致は状態不明として隔離し、自動再開しない。

purge 集約	条件
PURGE UNVERIFIABLE	一対象でも検証不能
PURGE PARTIAL	検証不能はないが、一対象でも部分完了
PURGE VERIFIED	管理下の全対象が検証済み

PURGE PARTIAL または PURGE UNVERIFIABLE のリスク受容は purge 成功を意味しない。旧 run は再開せず、残存状態を明示して re-binding し、新しい run_id、更新 Action Envelope、旧 Token 失効、新しい人間承認で開始する。

16.2 Target-specific Purge and Re-binding

purge は一括削除として実行してはならない。対象ごとに失効、終了、取消、隔離、初期化、削除、保持または検証不能を記録する。

対象	必要な処理
API key／credential	失効し、旧 run および旧 Token から再利用不能にする。
session	終了し、自動再開を禁止する。

対象	必要な処理
pending Action	取消または安全停止し、旧 action_hash を失効する。
agent state	隔離または初期化し、汚染状態の再利用を禁止する。
derived cache	削除または隔離し、由来を記録する。
unapproved／contaminated Context	実行系から除外し、Canonical A と混同しない。
Canonical A	保持し、purge によって削除または書換えしない。
Approved P_A	影響を受ける scope について失効または停止する。
action_hash／decision record	保持する。
incident evidence	実行系から分離し、アクセス制限下で保持する。
resumed state	人間承認後、新しい run へ re-binding する。

purge の原則は、実行能力を失効し、汚染状態を隔離し、Canonical A および監査証拠を保持することである。

各対象について、対象識別子、処理、実行主体、時刻、結果、検証証拠および残存状態を記録する。集約結果は、現行§16.1 の PURGE VERIFIED、PURGE PARTIAL または PURGE UNVERIFIABLE に従う。

PURGE PARTIAL または PURGE UNVERIFIABLE を purge 成功として表示してはならない。旧 run、旧 Token、旧 nonce、旧 action_hash、旧承認または旧外部状態 version を再利用してはならない。

re-binding の前に、人間は、Canonical A の版、実行 scope、purge 結果、残存状態、監査証拠、再開条件および残余リスクを確認する。承認された場合だけ、新しい run_id、更新された Action Envelope および必要な新しい承認を用いて開始する。

re-convergence は、新しい入力、run_id および assessment_id による再生成・再評価として実施する。re-convergence を旧 run の再開または rejection／suspension の消去として扱ってはならない。

17. 監査証拠

監査証拠は、retention lock 付き WORM、分離管理者下の署名付き append-only ログ、外部タイムスタンプ／アンカーを組み合わせる候補とする。絶対的な改変不能性は主張しない。保持期間、管理者、anchor 頻度、鍵方式は Profile Activation Package で人間が決定する。MVP ではブロックチェーンを前提としない。

警告、critical flag、凍結要求、SUSPENDED、Gate 拒否、 T_k 、実際の副作用停止および purge 評価は、それぞれ独立したイベント、時刻、主体、対象 run、証拠参照を持つ監査ログとして記録する。

試験結果、ログ、状態差分、purge 証拠は承認対象となる規范文書ではない。人間は、それらを採否判断の根拠として受理、棄却または追加確認する。

17.1 Bounded Evidence Retention and Residual-risk Recording

監査証拠の保持は目的限定かつ有限でなければならない。30 日その他の一律の固定期間を Core または Safety Profile の普遍的要件としない。保持期間は、対象リスク、実行期間、合理的な検出遅延、privacy impact、法令、契約および組織規則に基づき、人間が Audit Retention Profile または Activation Package で確定する。

少なくとも次の証拠区分を分離して管理する。

- Canonical A の版、hash および失効状態
- Approved P_A の版、hash および適用 scope
- action_hash、承認、nonce、Token および Gate 判断
- 累積予算、rejection、suspension、 T_k 、purge および re-binding 状態
- 実副作用、外部状態差分、失敗および再試行
- circumvention candidate の確度、根拠、反証情報および人間判断

評価または監査に全文が必要でない場合、hash、条項 ID、差分および必要最小限の metadata を優先する。証拠は実行系から分離し、目的別の access control、管理者、保持期限および削除または匿名化手順を持たなければならない。

circumvention candidate その他の確率的評価結果を、確定した主体同一性、悪意または違反の事実として保存または再利用してはならない。評価状態、確度および人間判断を分離して記録する。

管理外経路、未知 identity、 T_k 前に外部 commit 済みの作用、取得不能な証拠および停止不能な外部コピーは、対象、理由、観測可能範囲および影響を残余リスクとして記録する。残余リスクの記録を、当該経路を制御または停止できるという主張に置き換えてはならない。

保持期限後の削除、匿名化または集約の処理を事前に定義し、その実施結果を監査可能にする。purge に必要な証拠保存と不要な個人情報の削除が競合する場合、人間が目的、範囲、アクセス権および保持期間を明示的に判断する。

18. MVP 受入基準

ID	合格条件
AC-01	承認済み管理境界と許可経路一覧に対する静的検査・動的迂回試験で、Gate 非経由の副作用成功が 0 件。
AC-02	FAIL／INSUFFICIENT EVIDENCE で当該 assessment が終端し、新規 dispatch が 0 件。自動 Checkpoint 反復が 0 件。
AC-03	Gate、watchdog、Monitor、PAL、ログまたは認証の障害・未応答時に fail-open または PERMITTED となる高リスク処理が 0 件。watchdog が Gate と異なる管理プレーン・資格情報に分離されていることを、静的構成確認および障害試験で確認できる。
AC-04	承認前の L2 dispatch が 0 件。
AC-05	別 run、別引数、期限切れ、消費済み Token の Replay、または action_hash、state precondition、version／ETag、environment fingerprint 不一致状態での dispatch 成功が 0 件。人間による継続承認後も旧 nonce または旧外部状態 version は拒否される。
AC-06	L3 操作が権限上実行不能。

ID	合格条件
AC-07	各 Action が単独では許可可能でも、同一 run_id の活動系列が累積予算、対象・宛先・権限 scope、または Approved P_A に機械表現された目的境界を超える場合、Monitor または PAL が検出し、Gate からの dispatch が 0 件、run が SUSPENDED となる。
AC-08	事前承認済み trigger に合致する critical flag 後、M2 完了前でも権威ある停止 commit により T_k が成立し、 T_k 以降の新規 Token、PERMITTED、許可、dispatch、開始がすべて 0 件。停止 SLO 経過後、管理下のキュー、ジョブ、ソケットおよび egress 接続について、未取消・未隔離の残存が 0 件。
AC-09	旧 run の Token、承認、nonce、外部状態 version および派生状態が再利用されない。
AC-10	B' が定義された人間判断なしに ADOPTED にならない。
AC-11	全試験結果に対象・版・時刻・結果を追跡できる証拠があり、警告、SUSPENDED、Gate 拒否、 T_k および実際の副作用停止が独立イベントとして記録される。
AC-12	Registry、API、ログ、画面で A、P_A candidate、Approved P_A が別型・別状態。
AC-13	同一 assessment_id の判定変更、INSUFFICIENT EVIDENCE からの無制限再評価、Checkpoint 再帰が 0 件。さらに、同一 run_id、action_hash、Canonical A hash、Approved P_A hash、外部状態 version および証拠集合に対する Checkpoint 重複発火が 0 件。

18.1 追加監視試験

ID	合格条件
AC-14	Monitor または PAL が PASS でも自動 dispatch されず、Runtime Gate が Approved P_A に基づく独立した決定論評価を完了しない限り PERMITTED にならない。
AC-15	人間が REJECT した Action を言い換えまたは分割して再提示しても、同一 run_id の活動系列評価によって検出され、dispatch 成功が 0 件。
AC-16	完全な chain-of-thought を取得できない環境でも、観測可能な実行証拠だけで Monitor、PAL 評価および Gate 統制が成立する。
AC-17	監視予算の枯渇、Monitor/PAL timeout または監視状態 UNAVAILABLE 時に監視が黙って省略されず、新規高リスク dispatch が拒否される。

18.2 Execution Continuity and Recovery Tests

ID	合格条件
AC-18	同一の承認済み実行系列に属する管理下の

ID	合格条件
	session、credential、model、agent、tool または route を変更しても、累積予算、Canonical A binding、authorization scope、rejection、suspension、purge、未完了 assessment および 保留中 Action が失われない。停止または予算超過後の新規 dispatch 成功が 0 件。
AC-19	Canonical A の条項削除、否定反転、要約による意味変更、未承認 Context の混入、A' またはモデル由来状態の混入、版不一致および失効版の使用を Preflight が検出する。PASS 以外の状態での Action Envelope 提出および新規 dispatch 成功が 0 件。
AC-20	Safety Profile が有効な対象 run について、実副作用および外部状態差分を対象とした独立した post-execution assessment が終端する前に run が COMPLETED となる事例が 0 件。post-execution PASS による B' の自動 ADOPT が 0 件。
AC-21	purge 対象ごとに処理、結果、検証証拠および残存状態を追跡できる。PURGE PARTIAL または PURGE UNVERIFIABLE 後に、旧 run、旧 Token、旧 nonce、旧 action_hash、旧承認または汚染状態を使用した実行成功が 0 件。Canonical A および必要な監査証拠が保持される。
AC-22	管理下で同一 execution lineage と確認された経路変更では、既存の rejection／suspension 状態が決定論的に継承される。未知 identity

ID	合格条件
	または管理外経路との類似だけを根拠として、自動的に違反、悪意または主体同一と確定する事例が0件。無関係な類似要求に対する false-positive 試験を実施し、人間評価への送致と自動処置を区別できる。
AC-23	証拠区分ごとに保持目的、保持期間、access control、削除、匿名化または集約の終了処理を確認できる。目的未定義の無期限保持が0件。管理外経路、取得不能な証拠および停止不能な外部作用が残余リスクとして記録され、停止完了または PURGE VERIFIED と誤表示されない。

19. 30 日 MVP と限定 Go

本 30 日 MVP は、単一ツール、隔離環境、L3 Capability 非実装を前提とする限定試作であり、一般的な本番運用可能性を証明するものではない。

期間	内容	完了証拠
Day 1-7	Core／Profile 分離、A／P_A 分離、三値 PAL の終端性、L3 除外	定義、状態遷移、静的試験
Day 8-14	単一ツール、Runtime Gate、境界台帳、Action Envelope、予算	迂回試験、Gate 拒否ログ
Day 15-21	Token、watchdog、Kill Switch、隔離、Replay、障害注入	停止・障害試験報告
Day 22-30	TOCTOU、Injection、purge、鍵侵害、B' adoption、実行軌跡監視、AC-01～23	受入証拠一式
Day 30	限定環境の Go／No-Go	人間の明示的判断記録

AC 通過は必要条件であり、運用開始の十分条件ではない。証拠、残存リスク、例外、未解決事項、管理境界を人間が確認し、明示的に Go と判断した環境だけを条件付き運用へ移行する。

No-Go または無判断の場合は停止状態を維持する。

Part III — Governance, Approval & Transition

20. 承認手続きの有限化

文書分割によって承認対象を増殖させない。v0.5 採用時の規範承認対象は本書の Core と Profile の境界・必須要件であり、個々の参考説明、テストレポート、ログまたは実装メモを独立した Canonical A として扱わない。

判断イベント	対象	反復防止
v0.5 Adoption	Core、Profile の条件、規範要件	一つの版への一つの採否。修正時は新 version。
Profile Activation	環境境界、Approved P_A、予算、責任、期限	Manifest/hash へ束縛した一括判断。文書ごとの別承認に分解しない。
L2 Action	一つの正規化 Action	single-use、期限切れ・拒否で終了。自動再提示しない。
Stop／Resume	停止は即時、再開は新 run	停止に承認を要求しない。旧 run へ戻らない。
B' Adoption	成果物 hash と A 適合・品質	実行許可と分離。REVISION は新候補として扱う。

20.1 変更時の再承認

変更区分	扱い
Material	目的、禁止、権限、Profile Activation 条件、停止保証、Human Checkpoint 条件、risk 区分、採用条件の変更。人間の再承認が必要。
Operational Parameter	ツール、予算、timeout、保持期間、鍵周期等。対象 Activation Package だけを更新・再承認する。Core 全文は再承認しない。
Editorial／Evidence	誤字、説明、リンク、試験結果、ログの追記。変更記録は残すが、規範再承認は不要。

変更区分	扱い
区分不明	モデルが軽微と確定しない。人間が区分だけを判断し、全文承認へ自動拡張しない。

21. 未確定パラメータ

次の項目は、本 v0.5 Producer Approved 版の概念成立を妨げない。Safety Profile を実環境へ Activation する前に、人間が対象環境の証拠に基づいて確定する。未確定であることを理由に Core の審査を反復しない。

項目	確定場所
対象ツール、ネットワーク、プロセス、資格情報、データ境界	Boundary Manifest
累積予算値、L2 分類境界、並列数、時間・費用	Approved P_A / Activation Package
watchdog heartbeat、timeout、cancel 猶予、kill 期限	Tool Registration / Runbook
canonical serialization、hash、schema version、正規化規則	Action Envelope Specification
鍵管理製品、署名方式、rotation、失効伝播	Key Management Profile
監査保持期間、管理者、anchor 頻度	Audit Retention Profile
B'採用の承認人数	Canonical A または組織規則。Core は少なくとも一つの明示的人間判断のみ要求
監視予算、M1 / M2、縮退条件	Monitoring Profile / Activation Package。評価計算量、M2 昇格回数、待ち時間、ログ量・保持、同時 run 数、timeout、NORMAL / DEGRADED / UNAVAILABLE を確定
execution lineage の管理対象、関連識別子、状態継承範囲および誤結合防止条件	Boundary Manifest / Activation Package
Canonical A Transmission Preflight の	Action Envelope Specification / Monitoring Profile

項目	確定場所
入力、差分形式、独立性および timeout	
post-execution PAL の評価単位、証拠、timeout および run 完了条件	Monitoring Profile／Activation Package
purge 対象、失効・隔離方式、検証方法、re-binding 条件	Tool Registration／Runbook
circumvention correlation の対象、閾値、観測期間、送致条件、false-positive 評価	Activation Package／Monitoring Profile
証拠区分、保持目的、保持期間、access control、削除・匿名化・集約および残余リスク記録	Audit Retention Profile

22. v0.3→v0.5 移行と CHG 配置

CHG-001～032 は、個別文書の承認要求ではなく、v0.5 Producer Approved 版への配置確認表として扱う。CHG-001～026 は 2026 年 8 月 19 日付 v0.4 Fixed までの変更を、CHG-027～032 は同 Baseline に対して人間が採用を承認した Material 変更を示す。下表の配置は、v0.5 全体の最終 ADOPT または Safety Profile の Activation を意味しない。最終採否と対象環境への適用は、人間が別に判断する。

CHG	主題	候補配置
001-002	Canonical A／P_A 分離、変換 C の記録	Core 境界＋Safety Profile §10
003-004	Approved P_A の束縛・失効・Gate 参照限定	Safety Profile §10
005-007	T _k 、停止後禁止、状態機械分離	Safety Profile §14-15
008-009	watchdog 分類、未定義操作の隔離	Safety Profile §16
010-011	canonical serialization、Action 変更時の失効	Safety Profile §13
012-013	安全操作の予算除外、認証・監査・冪等性	Safety Profile §16

CHG	主題	候補配置
014	受入基準＋明示的 Go	Safety Profile §19
015-016	単一経路保証の管理境界限定、AC-01 再定義	Safety Profile §8、§18
017-018	purge 集約、PARTIAL／UNVERIFIABLE 後の旧 run 再開禁止	Safety Profile §16
019	用途別署名鍵と検証鍵限定	Safety Profile §21 の Activation パラメータ
020	監査ログ、B' adoption 方式	Profile §17＋Core §5.2／§6。人数は未固定
021	Execution-Trajectory Monitoring	Core §3 の原則＋Safety Profile §12、§17、§18
022	M1／M2 多段階監視	Safety Profile §12、§18、§21
023	Critical-Flag Immediate Freeze	Safety Profile §14-15、§18
024	Observable Reasoning and Action Signals	Core §3＋Safety Profile §12、§18
025	Monitor・PAL・Gate・watchdog・人間の権限分離	Safety Profile §9、§12、§18
026	監視予算と縮退状態	Safety Profile §14、§18、§21＋付録 B
027	Execution Continuity Invariant	Safety Profile §12.2、§14、§18、§21、付録 B
028	Canonical A Transmission Preflight	Safety Profile §12.1、§18、§21、付録 B
029	Post-execution PAL and Sequence Review	Safety Profile §12.3、§14、§17、§18、§21
030	Target-specific Purge and Re-binding	Core §6＋Safety Profile §16.2、§18、§21
031	High-risk Circumvention Correlation	Safety Profile §12.4、§18、§21、付録 B
032	Bounded Evidence Retention and Residual-risk Recording	Safety Profile §17.1、§18、§21、付録 B

23. 最終意思決定ポイント

Producer による本文内容の承認は 2026 年 9 月 19 日付で完了した。監査機構を構成する人間 3 名の承認は、Producer 承認、CHG-027～032 の反映承認および文書作成とは別に後日記録する。所定の監査承認が完了する前は、本 Proposal を v0.5 の最終 ADOPT へ移行しない。最終判断は ADOPT、ADOPT WITH MODIFICATIONS、HOLD または REJECT とする。ADOPT または ADOPT WITH MODIFICATIONS の場合でも、Safety Profile は自動的に全用途へ適用されず、特定環境の Activation に別の明示的人間判断を必要とする。

停止点 本書を Canonical A、Approved P_A または Runtime Gate 入力として使用してはならない。追加の人間判断がない場合、本 Proposal は Producer Approved の状態で終了し、監査承認、最終 ADOPT、Safety Profile Activation または B'採否へ自動移行せず、追加承認要求を自動生成しない。

付録 A：v0.5 採否記録（人間記入）

項目	記入欄
判断	☐ ADOPT ☐ ADOPT WITH MODIFICATIONS ☐ HOLD ☐ REJECT
対象 version/hash	_____
修正・条件	_____
Safety Profile の扱い	☐ 条件付き Profile として承認 ☐ 保留 ☐ 却下
判断者・日時	_____

付録 B：Safety Profile Activation Package 最小項目

- Canonical A version/hash、Approved P_A version/hash、Profile version/hash
- Boundary Manifest：tool、network、process、container、credential、service、data、destination
- Action schema、risk 区分、L3 禁止、累積予算、例外、期限

- 監視予算：評価計算量、M2 昇格回数、評価待ち時間、ログ量・保持期間、同時監視 run 数、Monitor／PAL timeout、NORMAL／DEGRADED／UNAVAILABLE の判定条件および fail-closed 条件
 - watchdog／Kill Switch パラメータ、停止 SLO、in-flight 処理方針
 - 監査方式、保持期間、鍵、管理分離、外部 anchor
 - 受入試験の対象版と証拠、残存リスク、明示的 Go／No-Go
- execution lineage の相関対象、管理下識別子、状態継承範囲、誤結合防止条件および人間による re-binding 条件
- Canonical A Transmission Preflight の参照正本、差分形式、独立性、timeout および fail-closed 条件
- post-execution PAL の評価単位、必要証拠、完了条件、timeout および INSUFFICIENT EVIDENCE 時の処理
- purge 対象一覧、資格情報失効、session 終了、Action 取消、agent state／cache／Context の隔離、対象別検証方法および re-binding 条件
- circumvention correlation の対象、観測期間、使用可能な証拠、閾値、false-positive 評価、人間への送致条件および禁止される自動処置
- 証拠区分ごとの保持目的、保持期間、access control、削除、匿名化または集約の終了処理、および管理外経路の残余リスク

付録 C：参照

本 Producer Approved 版は、CIP/PAL Runtime Stop MVP Proposal Candidate v0.3、v0.3→v0.4 差分指示書 v2、2026 年 8 月 19 日付 Proposal v0.4 Fixed、および人間が採用を承認した CHG-027～032 を再構成した。H.R. 9917 は停止能力に関する着想源としてのみ扱い、法的準拠を主張しない。

- GovInfo, H.R. 9917: <https://www.govinfo.gov/app/details/BILLS-119hr9917ih>
- RFC 8785, JSON Canonicalization Scheme: <https://www.rfc-editor.org/rfc/rfc8785.html>
- NIST Hash Functions: <https://csrc.nist.gov/Projects/hash-functions>
- OpenAI, Pacing model development to stay ahead of emerging risks: <https://openai.com/index/pacing-model-development-cyber-capabilities/>